

Labor Statistik – Rechnerübungen Statistik

Wintersemester 2026/2027 – NANUAG-Gesamtprojekt

Gruppe 02 – Version 01

Gruppenarbeit:	3 Studierende, Gruppe 02 von 8 Gruppen (G01–G08)
Werkzeug:	Python / Jupyter Notebook (keine Tabellenkalkulation)
Zwischenabgabe 1 (+ Präsentation):	KW 43/2026 (Termin 2)
Zwischenabgabe 2 (+ Präsentation):	KW 49/2026 (Termin 5)
Endabgabe (+ Abschlusspräsentation):	KW 2/2027 (Termin 7)
Puffer-/Nachholtermin:	KW 3/2027
Ihre Dateien:	Ordner Gruppe02/ (siehe Abschnitt 6)

Wichtige Hinweise:

- **Es wird dreimal abgegeben**, jeweils zusammen mit der zugehörigen Präsentation: eine **Zwischenabgabe 1** (Stand zur ersten Zwischenpräsentation), eine **Zwischenabgabe 2** (Stand zur zweiten Zwischenpräsentation) und eine **Endabgabe** (finaler Stand zur Abschlusspräsentation). Jede Abgabe besteht aus *einem* gemeinsamen Jupyter-Notebook, zusätzlich als PDF exportiert, in Moodle.
- Dateiname je Abgabe: `Projekt_Gruppe02_<Nachnamen>_Zwischenabgabe1.ipynb` bzw. `..._Zwischenabgabe2` bzw. `..._Endabgabe.ipynb` (+ jeweiliges PDF). Das Notebook wächst von Abgabe zu Abgabe – frühere Teile bleiben enthalten.
- Konkrete Wochentage und Uhrzeiten der Termine werden zeitnah bekanntgegeben; oben ist zunächst nur die **Kalenderwoche (KW)** angegeben.
- Geben Sie **niemals** die vollständige Tabelle mit ca. 100.000 Zeilen aus – nutzen Sie `.head()`, `.sample()`, Aggregationen und Diagramme.
- Nutzen Sie zur Selbstkontrolle laufend die Datei `Teilergebnisse_G02_V01.txt` (nur Kontrollwerte, kein Lösungsweg).

0. Rahmenhandlung

Die NANUAG ist ein mittelständischer Hersteller für Präzisionsbauteile mit mehreren Standorten in Deutschland. Ihre Gruppe wird von der Geschäftsführung beauftragt, in fünf aufeinander aufbauenden Teilprojekten verschiedene Fragestellungen rund um Personal, Unternehmensentwicklung, eine geplante Mitarbeiterlotterie, die Fertigungsqualität und eine aktuelle Diversity-Debatte statistisch zu untersuchen. Alle Teile verwenden entweder denselben Mitarbeiterdatensatz oder bauen inhaltlich aufeinander auf – lesen Sie daher die gesamte Aufgabenstellung, bevor Sie beginnen. Insbesondere greift **Teil 5** auf Vermutungen aus **Teil 1** und auf Messdaten aus **Teil 4** zurück.

1 Teil 1 – Personaldaten der NANUAG

Woche 1–3, vorzustellen in Zwischenpräsentation 1.

Die Personalabteilung möchte die Beschäftigtenstruktur des Unternehmens verstehen. In der Datei `nanuag_mitarbeiter_G02_V01.csv` finden Sie **ca. 100.000 Personaldatensätze** (Semikolontrennt): Personalnummer, Anrede (Herr/Frau/Divers), Vorname, Nachname, Geburtsdatum, Abteilung, Standort, Jahresgehalt, Führungsposition (Ja/Nein).

a) Einlesen – Lesen Sie die Daten in ein Pandas-DataFrame ein.

b) Datenbereinigung – Die Daten enthalten realistische Erfassungsfehler (textförmige/unmögliche/zukünftige Geburtsdaten, fehlende Werte, doppelte Personalnummern, unplausible Gehälter, Zufallszeichenketten in Namen). Entwickeln Sie eine **systematische, automatisierte** Bereinigungsstrategie. Behandeln Sie zusätzlich Gehaltsausreißer mit einer nachvollziehbaren, **rechnerischen** Regel (z. B.

IQR-Kriterium: Werte außerhalb $[Q_1 - 1,5 \cdot IQR, Q_3 + 1,5 \cdot IQR]$. Dokumentieren Sie in einer Tabelle, nach welcher Regel wie viele Datensätze betroffen waren.

c) Alter bestimmen – Berechnen Sie das Alter zum Stichtag 31.12.2026 (vollendete Lebensjahre).

d) Explorative Analyse – Erstellen Sie: (i) ein gruppiertes Säulendiagramm der Altersklassen (≤ 20 , 21–30, 31–40, 41–50, > 50) getrennt nach Anrede, (ii) je ein Tortendiagramm der Altersverteilung für Frauen und für Männer, (iii) ein Säulendiagramm der Mitarbeiterzahl je Abteilung, getrennt nach Anrede.

e) Kennzahlen – Mittelwert, empirische Varianz, empirische Standardabweichung, Median und Spannweite des Alters und des Jahresgehalts – jeweils gesamt sowie getrennt nach Anrede (4 Nachkommastellen).

f) Zusammenhangsanalyse – Berechnen Sie den Pearson- und den Spearman-Korrelationskoeffizienten zwischen Alter und Jahresgehalt. Unterscheiden sich beide deutlich? Was würde das bedeuten? Visualisieren Sie den Zusammenhang mit einem geeigneten Diagramm.

g) Diskussion – Fällt Ihnen in Ihren Kennzahlen aus e) bereits etwas zum Thema Gehaltsunterschied zwischen den Anreden auf? Formulieren Sie eine begründete Vermutung – Sie werden diese in Teil 5 statistisch prüfen.

2 Teil 2 – Unternehmensentwicklung

Woche 4–6, vorzustellen in Zwischenpräsentation 2.

Die Geschäftsleitung möchte die Umsatzentwicklung der NANUAG seit 1994 verstehen und eine Prognose für 2030 und 2035. In `nanuag_umsatz_G02_V01.txt` finden Sie den Jahresumsatz in Mio. € (feste Spaltenbreite, 1994–2026).

a) Streudiagramm der Umsatzentwicklung.

b) Regressionsanalyse – Untersuchen Sie je nach **Endziffer Ihrer Gruppennummer** (gerade/ungerade) die folgenden fünf Funktionstypen (Tabelle 1). Verwenden Sie **standardisierte** Jahreszahlen. Stellen Sie Regressionstyp, geschätzte Koeffizienten (inkl. Achsenabschnitt) und Bestimmtheitsmaß tabellarisch dar.

c) Kreuzvalidierung – Teilen Sie die Daten in Trainingsdaten (1994–2018) und Testdaten (2019–2026). Schätzen Sie alle fünf Modelle **nur** auf den Trainingsdaten und berechnen Sie sowohl R^2_{train} als auch R^2_{test} (bzw. RMSE) auf den Testdaten. Welche Modelle verschlechtern sich auf den Testdaten am stärksten? Warum?

d) Modellwahl – Wählen Sie die am besten geeignete Kurve unter Berücksichtigung von b) und c). Begründen Sie Ihre Wahl auch mit einem Residuenplot.

e) Diagramm mit eingezeichneter optimaler Kurve (auf allen Daten neu geschätzt).

f) Prognose 2030 und 2035 inkl. kritischer Einschätzung der Plausibilität. Vergleichen Sie Ihre Prognose mit der Prognose des Polynoms 6. Grades und diskutieren Sie anhand dieses Vergleichs das Problem der Extrapolation.

3 Teil 3 – Firmenlotterie „NANU-Glück“

Woche 4–8, vorzustellen in Zwischenpräsentation 2.

Als Mitarbeiter-Benefit plant die NANUAG eine interne Lotterie nach dem Muster von KENO: Ein Tippfeld besteht aus 70 Zahlen, 20 werden gezogen, Teilnehmende kreuzen 2–10 Zahlen an. Der Gewinnplan (Tabelle 7) entspricht den amtlichen KENO-Quoten (Stand 01.01.2005).

Gruppennummer (G02,G04,G06,G08)	gerade	Gruppennummer (G01,G03,G05,G07)	ungerade
Linear: $y = ax + b$		Linear: $y = ax + b$	
Polynom 2. Grades: $y = ax^2 + bx + c$		Polynom 2. Grades: $y = ax^2 + bx + c$	
Polynom 4. Grades		Polynom 3. Grades	
Polynom 6. Grades		Polynom 6. Grades	
Exponentialfunktion: $y = a e^{bx}$		Logarithmusfunktion: $y = a \ln(x) - b$	

Tabelle 1: Zuordnung der Regressionsfunktionen zu Teil 2b)

- a) Berechnen Sie Erwartungswert und Standardabweichung des Gewinns X_{10} bei Ankreuzen von 10 Zahlen und 2 € Einsatz (**vollständige Rechnung**, nicht nur Programmausgabe).
- b) Ebenso für $X_9, \dots, X_2$ – tabellarisch.
- c) Welche Anzahl angekreuzter Zahlen maximiert den Erwartungswert? Sollte die Personalabteilung die Lotterie überhaupt einführen (Diskussion Erwartungswert vs. Risiko/Standardabweichung)?
- d) **Individuelle Aufgabe** – Beantworten Sie die in `nanuag_lotterie_frage_G02_V01.txt` gestellte, gruppenspezifische Frage. Welche Verteilung verwenden Sie, welche Parameterwerte setzen Sie ein? Achten Sie auf die Unterscheidung „mindestens“ / „höchstens“ / „genau“.
- e) **Kombinationsspiel** – Eine Mitarbeiterin spielt bei **jeder** Ziehung gleichzeitig ein Tippfeld mit 10 Zahlen *und* ein Tippfeld mit 2 Zahlen (je 2 € Einsatz, unabhängige Ziehungsergebnisse innerhalb einer Ziehung sind hier nicht relevant – die beiden Tippfelder selbst sind stochastisch abhängig, da dieselben 20 Gewinnzahlen gezogen werden!). Ist die Annahme der **Unabhängigkeit** von X_{10} und X_2 hier gerechtfertigt? Begründen Sie, und berechnen Sie unter der in der Aufgabenstellung angenommenen Vereinfachung (Unabhängigkeit) Erwartungswert und Standardabweichung von $X_{10} + X_2$.

4 Teil 4 – Qualitätskontrolle in der Fertigung

Woche 8–11, vorzustellen in Zwischenpräsentation 2 oder Abschlusspräsentation.

Aus der Qualitätssicherung liegen drei Messreihen mit je **ca. 100.000 Einzelmessungen** vor (`nanuag_qc_G02_V01_MR1.txt`, `..._MR2.txt`, `..._MR3.txt`). Für jede Messreihe soll geprüft werden, ob eine Normalverteilung vorliegt.

- a) Kennzahlen (Mittelwert, empirische Varianz, empirische Standardabweichung, Median, Spannweite) für alle drei Messreihen.
- b) Histogramme für alle drei Messreihen. Begründen Sie Klassenanzahl und Klassenbreite **rechnerisch** (z. B. Sturges- oder Freedman-Diaconis-Regel). Vergleichen Sie mindestens zwei Regeln und begründen Sie Ihre finale Wahl.
- c) Entscheiden Sie anhand der Histogramme **und** mindestens eines weiteren Hilfsmittels (Q-Q-Plot **oder** Schiefe/Kurtosis-Kennzahlen) für jede Messreihe, ob Normalverteilung vorliegt.
- d) Für jede normalverteilte Messreihe: Diagramm mit Histogramm **und** angepasster Dichtekurve, inkl. Angabe der verwendeten Parameter μ und σ . Erläutern Sie den Skalierungsfaktor zwischen Histogrammhöhen und Dichtefunktionswerten.
- e) **Formaler Normalverteilungstest** – Führen Sie zusätzlich einen formalen Test durch (Shapiro-Wilk- oder Kolmogorov-Smirnov-Test mit geschätzten Parametern). **Hinweis:** Bei $n = 100.000$ sind formale Tests durch die hohe Teststärke fast immer signifikant, selbst bei praktisch vernachlässigbaren Abweichungen – und `scipy.stats.shapiro` ist zudem für $n > 5000$ nicht mehr zuverlässig.

Ziehen Sie daher eine Zufallsstichprobe (z. B. $n = 2000$) und diskutieren Sie das Phänomen „statistische vs. praktische Signifikanz“ anhand Ihres Ergebnisses.

5 Teil 5 – Statistische Tests: Gehalt, Führung und Abteilungszugehörigkeit

Woche 11–13, vorzustellen in der Abschlusspräsentation.

In Teil 1g) haben Sie eine Vermutung zum Gehaltsunterschied zwischen den Anreden formuliert. Nun prüfen Sie diese – und weitere Behauptungen – mit **vier verschiedenen** statistischen Tests auf dem 5%-Signifikanzniveau ab.

a) Gauß-Test (Einstichproben-Z-Test) – Laut Werksnorm soll Messreihe MR2 aus Teil 4 im Mittel dem Sollmaß $\mu_0 = 883,0$ entsprechen; die Prozess-Standardabweichung $\sigma_0 = 1,8$ gilt als **bekannt** (langjährige Erfahrungswerte der QS). Prüfen Sie mit einem Gauß-Test, ob die mittlere Messung Ihrer Fertigungslinie signifikant vom Sollmaß abweicht. Formulieren Sie H_0/H_1 , geben Sie Teststatistik und p-Wert an.

b) Zweistichproben-t-Test – Prüfen Sie mit einem geeigneten t-Test (begründen Sie die Wahl: gleiche/ungleiche Varianzen? Welch- oder Student-t-Test?), ob sich das mittlere Jahresgehalt von Mitarbeiterinnen und Mitarbeitern (Anrede „Herr“ vs. „Frau“, nach Bereinigung aus Teil 1b) signifikant unterscheidet. Was bedeutet Ihr Ergebnis fachlich – und was **nicht** (Kausalität vs. Korrelation)?

c) Binomialtest – Der Vorstand behauptet in einem Interview, „mindestens 30 % aller Führungspositionen bei der NANUAG sind mit Frauen besetzt“. Prüfen Sie diese Behauptung anhand der Spalte **Fuehrungsposition** mit einem einseitigen Binomialtest.

d) Chi-Quadrat-Unabhängigkeitstest – Erstellen Sie eine Kreuztabelle (Kontingenztafel) von Anrede und Abteilung. Prüfen Sie mit einem Chi-Quadrat-Unabhängigkeitstest, ob die Verteilung auf die Abteilungen unabhängig von der Anrede ist. Falls nicht: Könnte dieser Befund einen Teil des Ergebnisses aus b) miterklären (Stichwort: unterschiedliche Grundgehälter je Abteilung)? Diskutieren Sie kurz.

e) Mehrfachtestproblem – Sie haben in a)–d) **vier** Tests jeweils auf dem 5%-Niveau durchgeführt. Erläutern Sie, warum die Wahrscheinlichkeit für mindestens einen Fehler 1. Art dadurch über 5 % steigt. Berechnen Sie das Bonferroni-korrigierte Signifikanzniveau $\alpha' = \alpha/4$ und prüfen Sie, ob sich eine Ihrer vier Testentscheidungen dadurch ändert.

f) Management-Summary – Schreiben Sie eine kurze (max. 1 Seite) Zusammenfassung auf Deutsch, die alle fünf Teilprojekte zusammenfasst und der Geschäftsführung eine konkrete Handlungsempfehlung gibt.

6 Anhang A – Ihre Dateien

Alle Dateien liegen in Ihrem Gruppenordner **Gruppe02/**:

- **nanuag_mitarbeiter_G02_V01.csv** – Teil 1 (ca. 100.000 Zeilen)
- **nanuag_umsatz_G02_V01.txt** – Teil 2 (33 Zeilen, 1994–2026)
- **nanuag_lotterie_frage_G02_V01.txt** – Teil 3d)
- **nanuag_qc_G02_V01_MR1/2/3.txt** – Teil 4 (je ca. 100.000 Zeilen)
- **Teilergebnisse_G02_V01.txt** – Kontrollwerte zur Selbstprüfung

7 Anhang B – NANU-Glück Gewinnquoten

Auszahlung jeweils **je 1 € Einsatz**. Sonderregelungen für die jeweils höchsten Gewinnklassen bei 10 bzw. 9 getippten Zahlen werden – wie bisher – nicht berücksichtigt.

X_{10}		X_9		X_8	
Richtige	Auszahlung	Richtige	Auszahlung	Richtige	Auszahlung
10	100.000 €	9	50.000 €	8	10.000 €
9	1.000 €	8	1.000 €	7	100 €
8	100 €	7	20 €	6	15 €
7	15 €	6	5 €	5	2 €
6	5 €	5	2 €	4	1 €
5	2 €	0	2 €	0	1 €
0	2 €				

X_7		X_6		X_5	
Richtige	Auszahlung	Richtige	Auszahlung	Richtige	Auszahlung
7	1.000 €	6	500 €	5	100 €
6	100 €	5	15 €	4	7 €
5	12 €	4	2 €	3	2 €
4	1 €	3	1 €		

Bewertung

- Zwischenabgabe 1 + Zwischenpräsentation 1: 15 % – Zwischenabgabe 2 + Zwischenpräsentation 2: 20 % – Endabgabe + Abschlusspräsentation: 25 % – Gesamtqualität des finalen Notebooks (Code, Dokumentation, Korrektheit): 40 %.
- Jedes Gruppenmitglied muss in mindestens einer Präsentation aktiv vortragen und Rückfragen beantworten können.
- Details zu Terminen und Ablauf: siehe `Terminplan_WS2026_2027.xlsx`.

X_4		X_3		X_2	
Richtige	Auszahlung	Richtige	Auszahlung	Richtige	Auszahlung
4	22 €	3	16 €	2	6 €
3	2 €	2	1 €		
2	1 €				